

Машинное обучение

Лекция 12.2. Матричные разложения



Матричные разложения

$$X \approx U \cdot V^T$$
$$l \times n \quad l \times k \quad k \times n$$

Матричные разложения

$$X \approx U \cdot V^T$$
$$l \times n \quad l \times k \quad k \times n$$

$$||X - U \cdot V^T|| \rightarrow \min$$

Матричные разложения

$$X \approx U \cdot V^T$$
$$l \times n \quad l \times k \quad k \times n$$

$$\|X - U \cdot V^T\| \rightarrow \min$$

$$\|A\|_F = \sqrt{\sum_{i,j} {a_{ij}}^2}$$

Матричные разложения

$$X \approx U \cdot V^T$$
$$l \times n \quad l \times k \quad k \times n$$

$$\|X - U \cdot V^T\| \rightarrow \min$$

$$\sum_{i,j} (x_{ij} - \langle u_i, v_j \rangle)^2 \rightarrow \min$$

Матричные разложения


$$X \approx U \cdot V^T$$
$$l \times n \quad l \times k \quad k \times n$$

$$\|X - U \cdot V^T\| \rightarrow \min$$


$$\sum_{i,j} (x_{ij} - \langle u_i, v_j \rangle)^2 \rightarrow \min$$

$$x_{ij} \approx \langle u_i, v_j \rangle$$

Разбираемся с обозначениями



Разбираемся с обозначениями



$$x_{ij} \approx \langle u_i, v_j \rangle$$

SVD в линейной алгебре

$$X = U\Sigma V^T$$

U - ортогональная

\Sigma - диагональная

V - ортогональная


SVD в линейной алгебре

$$X = U\Sigma V^T$$

U - ортогональная

Σ - диагональная

V - ортогональная



Приближение матрицы с помощью SVD

$$X \approx U \cdot V^T$$
$$l \times n \quad l \times k \quad k \times n$$

$$\|X - U \cdot V^T\| \rightarrow \min$$

Приближение матрицы с помощью SVD

$$X \approx U \cdot V^T$$
$$l \times n \quad l \times k \quad k \times n$$


$$\|X - U \cdot V^T\| \rightarrow \min$$

$$X = \tilde{U} \Sigma \tilde{V}^T$$

Приближение матрицы с помощью SVD

$$X \approx U \cdot V^T$$
$$l \times n \quad l \times k \quad k \times n$$

$$X = \tilde{U} \Sigma \tilde{V}^T$$



Приближение матрицы с помощью SVD

$$X \approx U \cdot V^T$$

$l \times n \quad l \times k \quad k \times n$

$$\|X - U \cdot V^T\| \rightarrow \min$$

$$X = \tilde{U} \Sigma \tilde{V}^T$$

$\tilde{U}_k, \Sigma_k, \tilde{V}_k$ -усеченные матрицы из SVD

$$U = \tilde{U}_k \Sigma_k, \quad V = \tilde{V}_k$$

Приближение матрицы с помощью SVD

$$X \approx U \cdot V^T$$

$l \times n \quad l \times k \quad k \times n$

$$\|X - U \cdot V^T\| \rightarrow \min$$

$$X = \tilde{U} \Sigma \tilde{V}^T$$

$\tilde{U}_k, \Sigma_k, \tilde{V}_k$ -усеченные матрицы из SVD

$$U = \tilde{U}_k, \quad V = \tilde{V}_k \Sigma_k$$

Приближение матрицы с помощью SVD

$$X \approx U \cdot V^T$$

$l \times n \quad l \times k \quad k \times n$

$$\|X - U \cdot V^T\| \rightarrow \min$$

$$X = \tilde{U} \Sigma \tilde{V}^T$$

$\tilde{U}_k, \Sigma_k, \tilde{V}_k$ -усеченные матрицы из SVD

$$U = \tilde{U}_k \sqrt{\Sigma_k}, \quad V = \tilde{V}_k \sqrt{\Sigma_k}$$

“SVD” в машинном обучении

$$X \approx U \cdot V^T$$

$$l \times n \quad l \times k \quad k \times n$$

$$\sum_{i,j} (x_{ij} - \langle u_i, v_j \rangle)^2 \rightarrow \min$$

u_i - «профили» объектов

v_j - «профили» исходных признаков

Матрица рейтингов и SVD

| | Пила | Улица Вязов | Ванильное небо | 1+1 |
|------|------|-------------|----------------|-----|
| Маша | 5 | 4 | 1 | 2 |
| Юля | 5 | 5 | 2 | |
| Вова | | | 3 | 5 |
| Коля | 3 | | 4 | 5 |
| Петя | | | | 4 |
| Ваня | | 5 | 3 | 3 |

Матрица рейтингов и SVD

j

| | Пила | Улица Вязов | Ванильное небо | 1+1 |
|------|------|-------------|----------------|-----|
| Маша | 5 | 4 | 1 | 2 |
| Юля | 5 | 5 | 2 | |
| Вова | | | 3 | 5 |
| Коля | 3 | | 4 | 5 |
| Петя | | | | 4 |
| Ваня | | 5 | 3 | 3 |

i

Матрица рейтингов и SVD

| | j | Пила | Улица Вязов | Ванильное небо | 1+1 | |
|-----|-----|------|-------------|----------------|-----|---|
| i | | Маша | 5 | 4 | 1 | 2 |
| | | Юля | 5 | 5 | 2 | |
| | | Вова | | | 3 | 5 |
| | | Коля | 3 | | 4 | 5 |
| | | Петя | | | | 4 |
| | | Ваня | | 5 | 3 | 3 |

$$x_{ij} \approx \langle u_i, v_j \rangle$$

u_i - «интересы пользователей»
 v_j - «параметры фильмов»

Матрица частот слов и SVD

| | database | SQL | index | regression | likelihood | linear |
|-----|----------|-----|-------|------------|------------|--------|
| d1 | 24 | 21 | 9 | 0 | 0 | 3 |
| d2 | 32 | 10 | 5 | 0 | 3 | 0 |
| d3 | 12 | 16 | 5 | 0 | 0 | 0 |
| d4 | 6 | 7 | 2 | 0 | 0 | 0 |
| d5 | 43 | 31 | 20 | 0 | 3 | 0 |
| d6 | 2 | 0 | 0 | 18 | 7 | 16 |
| d7 | 0 | 0 | 1 | 32 | 12 | 0 |
| d8 | 3 | 0 | 0 | 22 | 4 | 2 |
| d9 | 1 | 0 | 0 | 34 | 27 | 25 |
| d10 | 6 | 0 | 0 | 17 | 4 | 23 |

Матрица частот слов и SVD

j

| | database | SQL | index | regression | likelihood | linear |
|----|----------|-----|-------|------------|------------|--------|
| d1 | 24 | 21 | 9 | 0 | 0 | 3 |
| d2 | 32 | 10 | 5 | 0 | 3 | 0 |
| d3 | 12 | 16 | 5 | 0 | 0 | 0 |
| d4 | 6 | 7 | 2 | 0 | 0 | 0 |
| i | d5 | 43 | 31 | 20 | 0 | 3 |
| | d6 | 2 | 0 | 0 | 18 | 7 |
| | d7 | 0 | 0 | 1 | 32 | 12 |
| | d8 | 3 | 0 | 0 | 22 | 4 |
| | d9 | 1 | 0 | 0 | 34 | 27 |
| | d10 | 6 | 0 | 0 | 17 | 4 |
| | | | | | | 23 |

Матрица частот слов и SVD

| | database | SQL | index | regression | likelihood | linear |
|---|----------|-----|-------|------------|------------|--------|
| i | d1 | 24 | 21 | 9 | 0 | 3 |
| | d2 | 32 | 10 | 5 | 0 | 3 |
| | d3 | 12 | 16 | 5 | 0 | 0 |
| | d4 | 6 | 7 | 2 | 0 | 0 |
| | d5 | 43 | 31 | 20 | 0 | 3 |
| | d6 | 2 | 0 | 0 | 18 | 7 |
| | d7 | 0 | 0 | 1 | 32 | 12 |
| | d8 | 3 | 0 | 0 | 22 | 4 |
| | d9 | 1 | 0 | 0 | 34 | 27 |
| | d10 | 6 | 0 | 0 | 17 | 4 |
| | | | | | | 23 |

$$\chi_{ij} \approx \langle u_i, v_j \rangle$$

u_i - «темы» документов

v_j - «темы» слов

Постановка задачи

$$Q = \sum_{i,j} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min_{u_i, v_j}$$

Градиентный спуск (GD)

$$Q = \sum_{i,j} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min_{u_i, v_j}$$

$$\begin{aligned} \frac{\partial Q}{\partial u_i} &= \sum_{\tilde{i},j} \frac{\partial}{\partial u_i} (\langle u_{\tilde{i}}, v_j \rangle - x_{\tilde{i}j})^2 = \sum_j 2(\langle u_i, v_j \rangle - x_{ij}) \frac{\partial \langle u_i, v_j \rangle}{\partial u_i} = \\ &= \sum_j 2(\langle u_i, v_j \rangle - x_{ij}) v_j \quad \varepsilon_{ij} = (\langle u_i, v_j \rangle - x_{ij}) - \text{ошибка на } x_{ij} \end{aligned}$$

$$u_i^{(t+1)} = u_i^{(t)} - \gamma_t \sum_j \varepsilon_{ij} v_j$$

Стохастический градиентный спуск (SGD)

GD:

$$u_i^{(t+1)} = u_i^{(t)} - \gamma_t \sum_j \varepsilon_{ij} v_j$$

$$v_j^{(t+1)} = v_j^{(t)} - \eta_t \sum_i \varepsilon_{ij} u_i$$

SGD:

$$u_i^{(t+1)} = u_i^{(t)} - \gamma_t \varepsilon_{ij} v_j$$

$$v_j^{(t+1)} = v_j^{(t)} - \eta_t \varepsilon_{ij} u_i$$

Для случайных i, j

Плюсы и минусы SGD

- +Простота реализации
- +Сходимость
- Медленно сходится
- Сложность выбора шага градиентного спуска (γ_t и η_t)
- При константном шаге сходится очень медленно

Идея ALS

$$Q \rightarrow \min_{u_i, v_j}$$

Повторяем до сходимости:

$$\frac{\partial Q}{\partial u_i} = 0 \quad \xrightarrow{\text{orange arrow}} \quad u_i \qquad \qquad \frac{\partial Q}{\partial v_j} = 0 \quad \xrightarrow{\text{orange arrow}} \quad v_j$$

Выписываем шаг в ALS

$$Q = \sum_{i,j} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min_{u_i, v_j}$$

$$\frac{\partial Q}{\partial u_i} = \sum_j 2(\langle u_i, v_j \rangle - x_{ij})v_j = 0 \quad \sum_j v_j \langle v_j, u_i \rangle = \sum_j x_{ij} v_j$$

$$\sum_j v_j {v_j}^T u_i = \sum_j x_{ij} v_j$$

$$\left(\sum_j v_j {v_j}^T \right) u_i = \sum_j x_{ij} v_j$$

A

b

ALS: итоговый алгоритм

Повторяем по случайным i, j до сходимости:

$$\left(\sum_j v_j {v_j}^T \right) u_i = \sum_j x_{ij} v_j \quad \rightarrow \quad u_i \quad (\text{решение системы линейных уравнений})$$

$$\left(\sum_i u_i {u_i}^T \right) v_j = \sum_i x_{ij} u_i \quad \rightarrow \quad v_j$$

Регуляризация

$$Q = \sum_{i,j} (\langle u_i, v_j \rangle - x_{ij})^2 + \alpha \sum_i \|u_i\|^2 + \beta \sum_j \|v_j\|^2 \rightarrow \min_{u_i, v_j}$$

α и β - небольшие положительные числа (0.001, 0.01, 0.05)

Отличия от рекомендаций

j

| | Пила | Улица Вязов | Ванильное небо | 1+1 |
|----------|------|-------------|----------------|-----|
| <i>i</i> | | | | |
| Маша | 5 | 4 | 1 | 2 |
| Юля | 5 | 5 | 2 | |
| Вова | | | 3 | 5 |
| Коля | 3 | ? | 4 | 5 |
| Петя | | | | 4 |
| Ваня | | 5 | 3 | 3 |

Модель прогнозирования

j

| | Пила | Улица Вязов | Ванильное небо | 1+1 |
|------|------|-------------|----------------|-----|
| i | | | | |
| Маша | 5 | 4 | 1 | 2 |
| Юля | 5 | 5 | 2 | |
| Вова | | | 3 | 5 |
| Коля | 3 | ? | 4 | 5 |
| Петя | | | | 4 |
| Ваня | | 5 | 3 | 3 |

$$x_{ij} \approx \langle u_i, v_j \rangle$$

u_i - «интересы пользователей»
 v_j - «параметры фильмов»

Оптимизируемый функционал

$$x_{ij} \approx \langle u_i, v_j \rangle$$

$$\sum_{i,j} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min$$

Сдвиг

$$x_{ij} \approx \boxed{\mu} + \langle u_i, v_j \rangle$$

$$\sum_{i,j} (\boxed{\mu} + \langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min$$

Базовые предикторы

$$x_{ij} \approx \mu + b_i^u + b_j^v + \langle u_i, v_j \rangle$$

$$\sum_{i,j} (\mu + b_i^u + b_j^v + \langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min$$

Регуляризация

$$\sum_{i,j} (\mu + b_i^u + b_j^v + \langle u_i, v_j \rangle - x_{ij})^2 + \alpha \sum_i \|u_i\|^2 + \beta \sum_j \|v_j\|^2 +$$

$$+ \gamma \sum_i {b_i^u}^2 + \delta \sum_j {b_j^v}^2 \rightarrow \min$$

И снова рекомендации: implicit разложения

j

| | Вечернее платье | Поднос для писем | iPhone 6s | Шуба D&G |
|----------|--------------------|---------------------|-----------|----------|
| <i>i</i> | | | | |
| Маша | 1 | | 1 | |
| Юля | 1 | 1 | | 1 |
| Вова | | 1 | 1 | |
| Коля | 1 | ? | 1 | |
| Петя | | 1 | 1 | |
| Ваня | | | 1 | 1 |


Почему нужно что-то менять

j

| | Вечернее платье | Поднос для писем | iPhone 6s | Шуба D&G |
|----------|--------------------|---------------------|-----------|----------|
| <i>i</i> | Маша | 1 | 1 | |
| Юля | 1 | 1 | | 1 |
| Вова | | 1 | 1 | |
| Коля | 1 | ? | 1 | |
| Петя | | 1 | 1 | |
| Ваня | | | 1 | 1 |

$$x_{ij} = 1 \approx \langle u_i, v_j \rangle$$

$$\sum_{i,j: x_{ij} \neq 0} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min$$



$$u_i = \frac{1}{\sqrt{d}} (1 \quad \dots \quad 1)$$

$$v_j = \frac{1}{\sqrt{d}} (1 \quad \dots \quad 1)$$

Explicit и implicit

- **Explicit feedback:** есть положительные и отрицательные пример (например, низкие и высокие оценки фильмов, лайки и дислайки и т.д.)
- **Implicit feedback:** есть только положительные (покупки, просмотры, лайки) или только отрицательные примеры (дислайки)

Implicit matrix factorization

$$\sum_{i,j} w_{ij} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min$$



Сумма по всем индексам (не
только по известным элементам
матрицы)

w_{ij} принимает большие значения для $x_{ij} \neq 0$
и значительно меньшие для $x_{ij} = 0$

Implicit ALS

$$\sum_{i,j} w_{ij} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min$$


$$w_{ij} = 1 + \alpha |x_{ij}| \quad \alpha = 10, 100, 1000$$

u_i, v_j оцениваем с помощью ALS

Постановка задачи в "SVD"

$$Q = \sum_{i,j} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min_{u_i, v_j}$$

Нормальное распределение



$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Связь "SVD" и нормального распределения

$$x_{ij} = \langle u_i, v_j \rangle + \varepsilon \quad \varepsilon \sim \mathcal{N}(0, \sigma^2)$$

$$x_{ij} \sim \mathcal{N}(\langle u_i, v_j \rangle, \sigma^2)$$

$$\prod_{i,j} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_{ij}-\langle u_i, v_j \rangle)^2}{2\sigma^2}} \rightarrow max$$

$$\sum_{i,j} \frac{(x_{ij} - \langle u_i, v_j \rangle)^2}{2\sigma^2} - \frac{1}{2} \ln 2\pi\sigma^2 \rightarrow min$$


$$\sum_{i,j} (x_{ij} - \langle u_i, v_j \rangle)^2 \rightarrow min$$

Какое распределение подходит больше

| | database | SQL | index | regression | likelihood | linear |
|-----|----------|-----|-------|------------|------------|--------|
| d1 | 24 | 21 | 9 | 0 | 0 | 3 |
| d2 | 32 | 10 | 5 | 0 | 3 | 0 |
| d3 | 12 | 16 | 5 | 0 | 0 | 0 |
| d4 | 6 | 7 | 2 | 0 | 0 | 0 |
| d5 | 43 | 31 | 20 | 0 | 3 | 0 |
| d6 | 2 | 0 | 0 | 18 | 7 | 16 |
| d7 | 0 | 0 | 1 | 32 | 12 | 0 |
| d8 | 3 | 0 | 0 | 22 | 4 | 2 |
| d9 | 1 | 0 | 0 | 34 | 27 | 25 |
| d10 | 6 | 0 | 0 | 17 | 4 | 23 |

Распределение Пуассона

$$X \sim Poiss(\lambda)$$



$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda} \quad \mathbb{E}X = \lambda$$

Распределение Пуассона и матричные разложения

$$x_{ij} \sim Poiss(\langle u_i, v_j \rangle) \quad P(x_{ij}) = \frac{\langle u_i, v_j \rangle^{x_{ij}}}{x_{ij}!} e^{-\langle u_i, v_j \rangle}$$

$$\prod_{i,j} \frac{\langle u_i, v_j \rangle^{x_{ij}}}{x_{ij}!} e^{-\langle u_i, v_j \rangle} \rightarrow max$$

$$\sum_{i,j} \langle u_i, v_j \rangle - x_{ij} \ln \langle u_i, v_j \rangle + \ln x_{ij}! \rightarrow min$$

$$\sum_{i,j} \langle u_i, v_j \rangle - x_{ij} \ln \langle u_i, v_j \rangle \rightarrow min$$

SGD для NMF (Non-negative matrix factorization)

$$Q = \sum_{i,j} \langle u_i, v_j \rangle - x_{ij} \ln \langle u_i, v_j \rangle \rightarrow \min$$

$$\frac{\partial Q}{\partial u_i} = \sum_j v_j - \frac{x_{ij}}{\langle u_i, v_j \rangle} v_j = \sum_j \underbrace{\frac{\langle u_i, v_j \rangle - x_{ij}}{\langle u_i, v_j \rangle}}_{\tilde{\varepsilon}_{ij} -} v_j \rightarrow \min$$

$\tilde{\varepsilon}_{ij}$ -

«относительная
ошибка» прогноза

SGD:

$$u_i^{(t+1)} = u_i^{(t)} - \gamma_t \tilde{\varepsilon}_{ij} v_j$$


$$v_j^{(t+1)} = v_j^{(t)} - \eta_t \tilde{\varepsilon}_{ij} u_i$$

Другие неотрицательные матричные разложения

Можно использовать норму Фробениуса, но добавить ограничения неотрицательности для U и V :


$$Q = \sum_{i,j} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min_{\substack{u_i, v_j: \\ u_{ik} \geq 0 \\ v_{jk} \geq 0}}$$

Еще немного про обозначения





$$x_{ij} \approx \langle u_i, v_j \rangle$$

Еще немного про обозначения





$$x_{ij} \approx \langle u_i, v_j \rangle$$

Еще немного про обозначения




$$x_{ij} \approx \langle u_i, v_j \rangle$$



Еще немного про обозначения




$$x_{ij} \approx \langle u_i, v_j \rangle$$



Еще немного про обозначения




$$x_{ij} \approx \langle u_i, v_j \rangle$$




$$x_{ij} \approx u_i^T v_j$$

Аналогия с матрицей признаков



В линейных моделях:

$$\langle w, x_i \rangle = w^T x_i$$



Какие обозначения встречаются

$$X \approx UV^T$$

$$X \approx PQ^T$$

$$X \approx WH$$

$$X \approx \Phi\Theta$$



info@applieddatascience.ru



https://t.me/joinchat/B10lThC96v0BQCvs_joNew



https://github.com/vkantor/ml2018jan_feb